

Instituto Tecnológico y de Estudios Superiores de Monterrey

TC5044.10 — Operaciones de Aprendizaje Automático

Fase 1 — Avance de Proyecto

MiBici

Preparación, exploración y trazabilidad de datos para el pronóstico de salidas por estación y hora

Equipo 04

José Eduardo De Moraes López — A01634782

Erik Román Cortez — A01793714

José Emmanuel Vázquez Galán — A01797507

Leonardo Santos García — A01797367

25 de octubre de 2026

Repositorio del proyecto

1. Resumen ejecutivo

El proyecto MiBici aborda el pronóstico de viajes iniciados por estación y por hora para el día siguiente, con el objetivo de apoyar la planeación del rebalanceo de bicicletas. La propuesta busca aportar información sobre dónde y cuándo se concentrarán las salidas. El pronóstico será un insumo para la operación; no determina por sí solo el inventario requerido ni las rutas de los vehículos de rebalanceo.

En la Fase 1 se construyó una base reproducible para ese problema a partir de los datos abiertos de MiBici. Se adquirieron 142 archivos mensuales de viajes y una nomenclatura de estaciones, con un histórico de diciembre de 2014 a septiembre de 2026 y 39,078,984 registros originales. La preparación normalizó formatos, tipos, faltantes y fechas; agregó linaje y marcas de calidad; y eliminó únicamente 758 duplicados exactos. El resultado fue `interim_v1`, con 39,078,226 viajes.

El equipo desarrolló análisis independientes de patrones temporales, estacionalidad y anomalías, y expansión de estaciones. La integración contrastó sus hallazgos con una base estación × hora y permitió definir el periodo desde enero de 2022, las horas de servicio y las reglas de conteo del target. Se conservaron las estaciones nuevas y los días extraordinarios, incorporando marcas para su evaluación posterior. Los viajes excluidos del target permanecen en interim.

El dataset resultante, `processed_v1`, contiene 11,949,160 observaciones de estación × hora, 473 estaciones representadas durante el periodo y 20,296,886 salidas. Cada estación-día elegible cuenta con 20 intervalos de servicio; el 42.8 % de las observaciones registra cero salidas. Su conciliación con los viajes intermedios permite explicar cada exclusión sin pérdidas de registros no documentadas.

La trazabilidad se implementó con Git y MLflow: versiones de código, reglas, métricas, reportes, referencias de datasets y huellas de datos. La lógica reutilizable reside en módulos Python y se ejecuta mediante Makefile en el ambiente Conda `mibici`. La verificación técnica confirmó 31 pruebas satisfactorias y revisiones de Ruff sin errores. El trabajo de preparación e integración quedó incorporado a la rama principal del repositorio público mediante Pull Requests que conservan las contribuciones individuales.

La fase deja datos y componentes preparados para iniciar el modelado. No se entrenó un modelo final ni se midió un beneficio operativo. La disponibilidad mensual de los datos públicos limita el proyecto a una simulación histórica del contrato diario hasta contar con una fuente más oportuna.

2. Análisis de requerimientos y propuesta de valor

2.1 Problema y beneficiario

La coordinación de operaciones y logística de MiBici se plantea como beneficiaria de la solución. Esta identificación es un supuesto de trabajo del equipo, sin validación mediante contacto directo con la organización. La necesidad es anticipar las salidas para apoyar la priorización de estaciones y franjas horarias en la planeación del rebalanceo.

Una estación sin bicicletas puede impedir que se inicie un viaje; una estación sin anclajes disponibles puede dificultar su devolución. Sin embargo, el histórico utilizado registra viajes realizados y no contiene inventario, ocupación ni intentos fallidos. Por ello, el problema se delimitó a las salidas observadas, evitando afirmar que se pronostica demanda total o demanda no satisfecha.

La propuesta de valor consiste en proporcionar un pronóstico desagregado por estación y hora que incorpore patrones temporales y diferencias entre estaciones. Su utilidad operativa dependerá de combinarlo posteriormente con información interna y restricciones de operación. En esta fase no se cuantifica ahorro, reducción de estaciones vacías ni mejora del servicio.

2.2 Tarea y contrato de predicción

El problema se formula como aprendizaje supervisado de conteos sobre series de tiempo. El target es:

$$y_{s,t} \in \mathbb{N}_0$$

donde s identifica una estación y t un intervalo horario. El valor observado es el número de viajes que comienzan en esa estación durante el intervalo, después de aplicar las reglas de inclusión del target.

Elemento	Definición acordada
Unidad	Estación × hora de servicio
Target	`departures`: salidas observadas que cumplen las reglas del dataset procesado
Corte de información	Antes de las 22:00 del día d
Horizonte	Los intervalos de servicio del día $d+1$
Horas incluidas	00:00–00:59 y 05:00–23:59: 20 intervalos
Uso previsto	Apoyar la planeación del rebalanceo del día siguiente
Disponibilidad actual	Publicaciones mensuales; el contrato diario se estudiará mediante simulación histórica

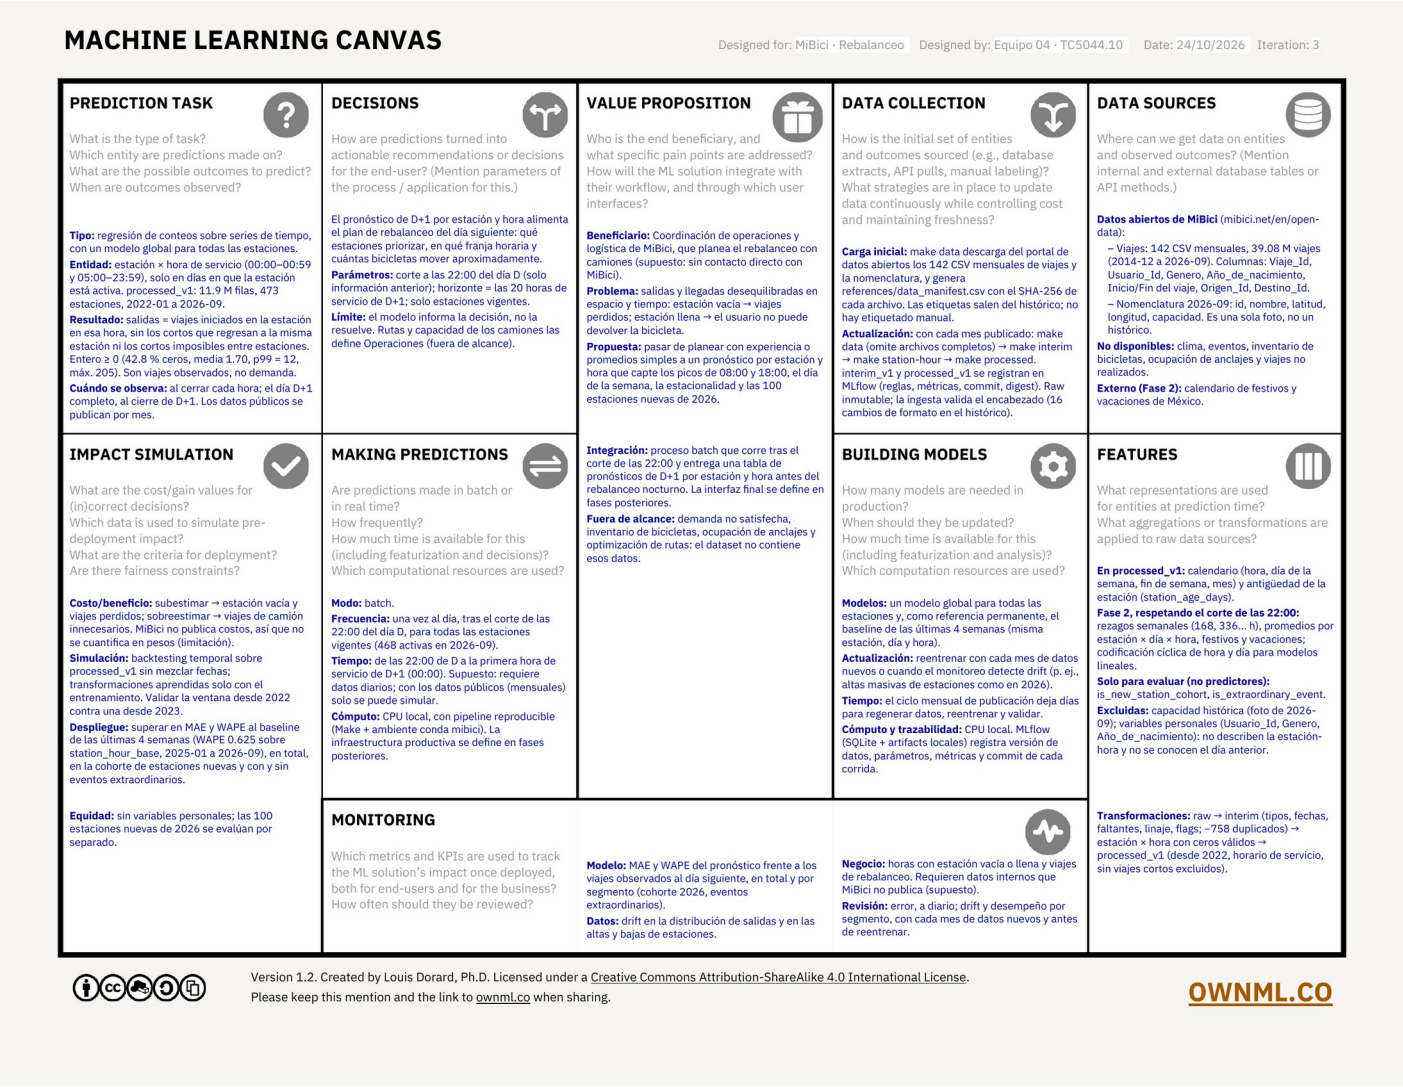
El corte establece qué información podrá utilizarse en futuras variables de rezago. No representa un servicio productivo ya implementado ni una garantía de disponibilidad de los datos antes de esa hora.

2.3 ML Canvas y alcance

El ML Canvas v3 consolida la tarea, propuesta de valor, fuentes, supuestos, contrato de predicción y criterios previstos de evaluación. Se utiliza como referencia oficial de requerimientos del proyecto; sus bloques de entrenamiento, operación y monitoreo describen trabajo futuro.

Aspecto del Canvas	Síntesis para la evaluación del proyecto
Propuesta de valor	Anticipar las salidas por estación y hora para apoyar una planeación proactiva del rebalanceo
Decisión apoyada	Priorizar estaciones y franjas horarias; la asignación de inventario y las rutas requieren información y restricciones operativas adicionales
Evaluación técnica prevista	Comparar MAE y WAPE con una referencia estacional sencilla, sobre el mismo target y periodo de evaluación
Impacto operativo por evaluar	Reducción de horas con estaciones vacías o llenas y eficiencia del rebalanceo; requiere datos de inventario, ocupación y operación que no están disponibles en este dataset

Quedan fuera de la Fase 1 el entrenamiento de modelos finales, la optimización de rutas, la estimación de inventario y el despliegue. La ausencia de información sobre viajes no realizados impide evaluar directamente la demanda no satisfecha.



MACHINE LEARNING CANVAS

Designed for: MiBici · Rebalanceo | Designed by: Equipo 04 · TC5044.10 | Date: 24/10/2026 | Iteration: 3

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Tipo: regresión de conteos sobre series de tiempo, con un modelo global para todas las estaciones.
Entidad: estación × hora de servicio (00:00–00:59 y 05:00–23:59), solo en días en que la estación está activa. processed_v1: 11.9 M filas, 473 estaciones, 2022-01 a 2026-09.
Resultado: salidas = viajes iniciados en la estación en esa hora, sin los cortos que regresan a la misma estación ni los cortos imposibles entre estaciones. Entero ≥ 0 (42.8 % ceros, media 1.70, p99 = 12, máx. 205). Son viajes observados, no demanda.
Cuándo se observa: al cerrar cada hora; el día D+1 completo, al cierre de D+1. Los datos públicos se publican por mes.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

El pronóstico de D+1 por estación y hora alimenta el plan de rebalanceo del día siguiente: qué estaciones priorizar, en qué franja horaria y cuántas bicicletas mover aproximadamente.
Parámetros: corte a las 22:00 del día D (solo información anterior); horizonte = las 20 horas de servicio de D+1; solo estaciones vigentes.
Límite: el modelo informa la decisión, no la resuelve. Rutas y capacidad de los camiones las define Operaciones (fuera de alcance).

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiario: Coordinación de operaciones y logística de MiBici, que planea el rebalanceo con camiones (supuesto: sin contacto directo con MiBici).
Problema: salidas y llegadas desequilibradas en espacio y tiempo: estación vacía → viajes perdidos; estación llena → el usuario no puede devolver la bicicleta.
Propuesta: pasar de planear con experiencia o promedios simples a un pronóstico por estación y hora que capte los picos de 08:00 y 18:00, el día de la semana, la estacionalidad y las 100 estaciones nuevas de 2026.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Carga inicial: make data descarga del portal de datos abiertos los 142 CSV mensuales de viajes y la nomenclatura, y genera references/data_manifest.csv con el SHA-256 de cada archivo. Las etiquetas salen del histórico; no hay etiquetado manual.
Actualización: con cada mes publicado: make data (omite archivos completos) → make interim → make station-hour → make processed. interim_v1 y processed_v1 se registran en MLflow (reglas, métricas, commit, digest). Raw inmutable; la ingesta valida el encabezado (16 cambios de formato en el histórico).

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Datos abiertos de MiBici (mibici.net/en/open-data):
- Viajes: 142 CSV mensuales, 39.08 M viajes (2014-12 a 2026-09). Columnas: Viaje_Id, Usuario_Id, Genero, Año_de_nacimiento, Inicio/Fin del viaje, Origen_Id, Destino_Id.
- Nomenclatura 2026-09: id, nombre, latitud, longitud, capacidad. Es una sola foto, no un histórico.

No disponibles: clima, eventos, inventario de bicicletas, ocupación de anclajes y viajes no realizados.
Externo (Fase 2): calendario de festivos y vacaciones de México.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costo/beneficio: subestimar → estación vacía y viajes perdidos; sobreestimar → viajes de camión innecesarios. MiBici no publica costos, así que no se cuantifica en pesos (limitación).
Simulación: backtesting temporal sobre processed_v1 sin mezclar fechas; transformaciones aprendidas solo con el entrenamiento. Validar la ventana desde 2022 contra una desde 2023.
Despliegue: superar en MAE y WAPE al baseline de las últimas 4 semanas (WAPE 0.625 sobre station_hour_base, 2025-01 a 2026-09), en total, en la cohorte de estaciones nuevas y con y sin eventos extraordinarios.

Equidad: sin variables personales; las 100 estaciones nuevas de 2026 se evalúan por separado.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Modo: batch.
Frecuencia: una vez al día, tras el corte de las 22:00 del día D, para todas las estaciones vigentes (468 activas en 2026-09).
Tiempo: de las 22:00 de D a la primera hora de servicio de D+1 (00:00). Supuesto: requiere datos diarios; con los datos públicos (mensuales) solo se puede simular.
Cómputo: CPU local, con pipeline reproducible (Make + ambiente conda mibici). La infraestructura productiva se define en fases posteriores.

Integración: proceso batch que corre tras el corte de las 22:00 y entrega una tabla de pronósticos de D+1 por estación y hora antes del rebalanceo nocturno. La interfaz final se define en fases posteriores.
Fuera de alcance: demanda no satisfecha, inventario de bicicletas, ocupación de anclajes y optimización de rutas: el dataset no contiene esos datos.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Modelos: un modelo global para todas las estaciones y, como referencia permanente, el baseline de las últimas 4 semanas (misma estación, día y hora).
Actualización: reentrenar con cada mes de datos nuevos o cuando el monitoreo detecte drift (p. ej., altas masivas de estaciones como en 2026).
Tiempo: el ciclo mensual de publicación deja días para regenerar datos, reentrenar y validar.
Cómputo y trazabilidad: CPU local. MLflow (SQLite + artifacts locales) registra versión de datos, parámetros, métricas y commit de cada corrida.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

En processed_v1: calendario (hora, día de la semana, fin de semana, mes) y antigüedad de la estación (station_age_days).
Fase 2, respetando el corte de las 22:00: rezagos semanales (168, 336… h), promedios por estación × día × hora, festivos y vacaciones; codificación cíclica de hora y día para modelos lineales.
Solo para evaluar (no predictores): is_new_station_cohort, is_extraordinary_event.
Excluidas: capacidad histórica (foto de 2026-09); variables personales (Usuario_Id, Genero, Año_de_nacimiento): no describen la estación-hora y no se conocen el día anterior.

Transformaciones: raw → interim (tipos, fechas, faltantes, linaje, flags; −758 duplicados) → estación × hora con ceros válidos → processed_v1 (desde 2022, horario de servicio, sin viajes cortos excluidos).

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Modelo: MAE y WAPE del pronóstico frente a los viajes observados al día siguiente, en total y por segmento (cohorte 2026, eventos extraordinarios).
Datos: drift en la distribución de salidas y en las altas y bajas de estaciones.

Negocio: horas con estación vacía o llena y viajes de rebalanceo. Requieren datos internos que MiBici no publica (supuesto).
Revisión: error, a diario; drift y desempeño por segmento, con cada mes de datos nuevos y antes de reentrenar.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

Figura 1. ML Canvas v3 del Equipo 04. Síntesis del problema, propuesta de valor, datos, contrato de predicción y evaluación prevista. Fuente: documento del equipo sobre la plantilla Machine Learning Canvas de Louis Dorard. Se conserva la atribución y licencia de la plantilla.

3. Dataset y preparación de datos

3.1 Fuente, cobertura y adquisición

La fuente es el portal de datos abiertos de MiBici. Los archivos originales se almacenan en `data/raw/` y no se modifican manualmente. La adquisición genera un manifest con nombre, URL, tamaño y SHA-256 de cada archivo, que permite identificar las fuentes utilizadas.

Característica	Resultado
Archivos mensuales de viajes	142
Archivo de nomenclatura	1, correspondiente a septiembre de 2026
Periodo de viajes	Diciembre de 2014–septiembre de 2026
Registros originales	39,078,984
Días con viajes en el histórico	4,322
Filas de la nomenclatura	484

Los registros de viajes incluyen identificadores de viaje y usuario, género, año de nacimiento, fecha de inicio y fin, y estaciones de origen y destino. La nomenclatura contiene identificador, nombre, latitud, longitud y capacidad. Es una fotografía de septiembre de 2026, no un historial de atributos de estación.

3.2 Preparación de `interim_v1`

El diagnóstico detectó heterogeneidad física entre archivos, aunque las ocho columnas originales conservan su significado. La preparación atiende estas diferencias mediante reglas explícitas y reutilizables.

Tratamiento	Aplicación y propósito
Lectura y encabezados	Detección de codificación y validación del layout antes de normalizar nombres; evita cruzar columnas silenciosamente
Fechas	Interpretación de los formatos ISO y día/mes/año; conservación de `datetime_format` para distinguir resolución temporal
Faltantes	Unificación de vacíos y marcadores a valores nulos reales; sin eliminar el viaje por ausencia de atributos personales
Tipos	Identificadores y años como enteros apropiados, fechas como datetime y variables repetitivas como categorías
Linaje	`source_file` y `source_sha256` en cada viaje
Duración	Diferencia entre fin e inicio expresada en segundos
Duplicados	Eliminación de filas duplicadas en las ocho columnas originales

Tratamiento	Aplicación y propósito
Anomalías	Flags de calidad; su presencia no elimina automáticamente el registro en interim
Estaciones	Unión del catálogo con actividad observada y resumen del ciclo de vida

Tres archivos —noviembre de 2023 y septiembre y octubre de 2024— registran fechas con resolución al minuto. Se conserva esa característica porque una duración registrada como cero puede reflejar la precisión de la fuente y no una duración real nula.

3.3 Resultado de la preparación y calidad

La única eliminación en interim corresponde a 758 duplicados exactos de septiembre de 2026:

$$39{,}078{,}984 - 758 = 39{,}078{,}226 \text{ viajes en interim.}$$

Indicador de calidad en interim	Viajes marcados
Duración negativa	0
Duración cero	55,038
Menos de 60 segundos y misma estación	1,205,672
Menos de 60 segundos y estaciones distintas	63,736
Duración superior a 24 horas	1,832
Año de nacimiento implausible	2,689
Origen sin metadatos en nomenclatura	2,023
Destino sin metadatos en nomenclatura	2,188

Los flags pueden coincidir en un mismo viaje y no deben sumarse como si fueran categorías excluyentes. Sus conteos y umbrales quedan documentados en los reportes de calidad y en MLflow.

La tabla `stations.parquet` reúne 487 estaciones: 486 con viajes y 484 con metadatos. Se identifican 100 estaciones con primera actividad desde enero de 2026, 16 retiradas según la regla de actividad y 40 con meses inactivos dentro de su vida observada. Estos indicadores se calculan con las definiciones de ciclo de vida implementadas en la preparación de interim.

`interim_v1` se guarda en Parquet particionado por año, junto con la tabla separada de estaciones. Esta capa preserva viajes y anomalías para que las decisiones posteriores puedan revisarse sin alterar raw.

4. Exploración de datos

El EDA se distribuyó en tres preguntas independientes y una integración. Todos parten de `interim_v1`; las exclusiones finales se deciden después de examinar la evidencia.

4.1 Patrones temporales — José Eduardo De Moraes López

El notebook 1.01 estudia cómo cambian las salidas por hora y día de la semana. Calcula promedios diarios para evitar comparar totales afectados por el número de días observados y contrasta perfiles normalizados de 2018–2019 y 2024–2026. Su periodo de análisis general es 2018–2026.

Los resultados muestran dos picos en días laborales, alrededor de las 08:00 y las 18:00, mientras que el fin de semana concentra más actividad hacia el mediodía. Los perfiles agregados apoyan mantener resolución horaria e incluir calendario. Las explicaciones relacionadas con trabajo, escuela o recreación son interpretaciones; el dataset no registra el motivo del viaje.

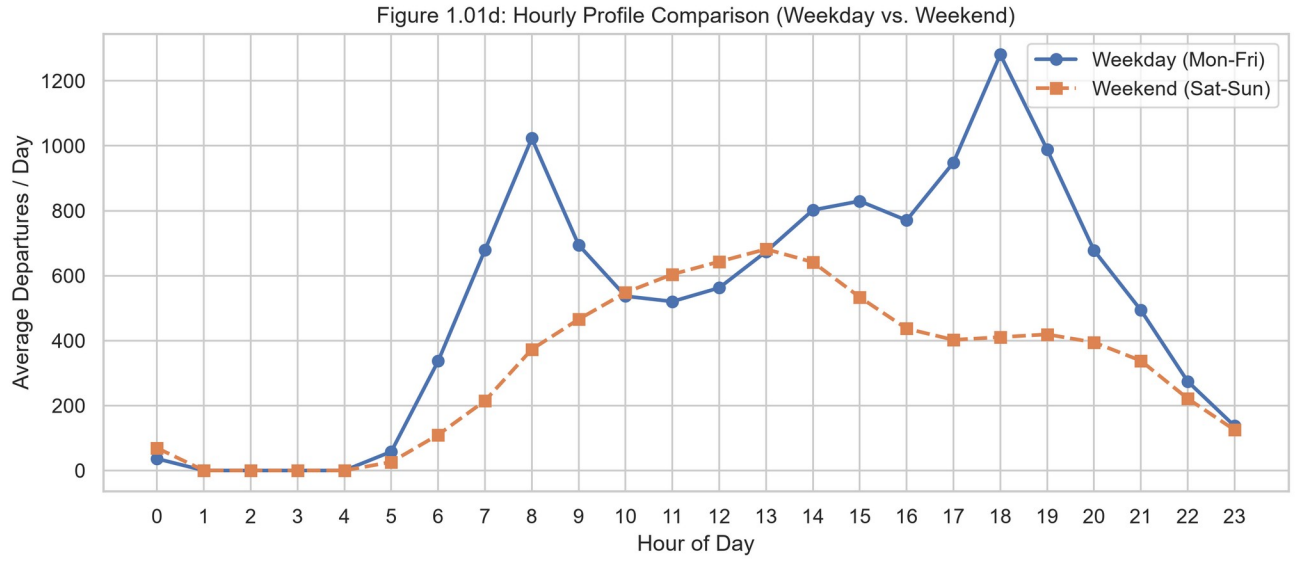


Figura 2. Perfil horario de salidas en días laborales y fines de semana. Fuente: notebook 1.01, José Eduardo. Los patrones corresponden al conjunto de la red y no prueban que todas las estaciones compartan la misma forma.

El resumen temporal se genera desde interim mediante la lógica incorporada en el PR #6. El notebook integrador realiza además una verificación desde la base común: reproduce los picos principales y obtiene una correlación aproximada de 0.98 entre perfiles laborales de los periodos comparados. Esto respalda similitud de forma, no igualdad de volúmenes ni estabilidad individual de cada estación.

4.2 Estacionalidad y anomalías — Erik Román Cortez

El notebook 1.02 analiza cambios mensuales, anuales y días atípicos. Para separar parcialmente crecimiento de la red y actividad, calcula salidas por día y estación con salidas observadas. Normaliza cada mes respecto del promedio de su año y compara 2020–2021 con los mismos meses de 2019.

El índice estacional de referencia sitúa octubre alrededor de 1.11 y diciembre en 0.88. Abril de 2020 registra aproximadamente 64 % menos actividad por día y estación que abril de 2019, seguido por una recuperación prolongada. La evidencia permite distinguir

el periodo 2020–2021 y proponer una ventana inicial desde 2022, sin demostrar todavía que sea la ventana predictiva óptima.

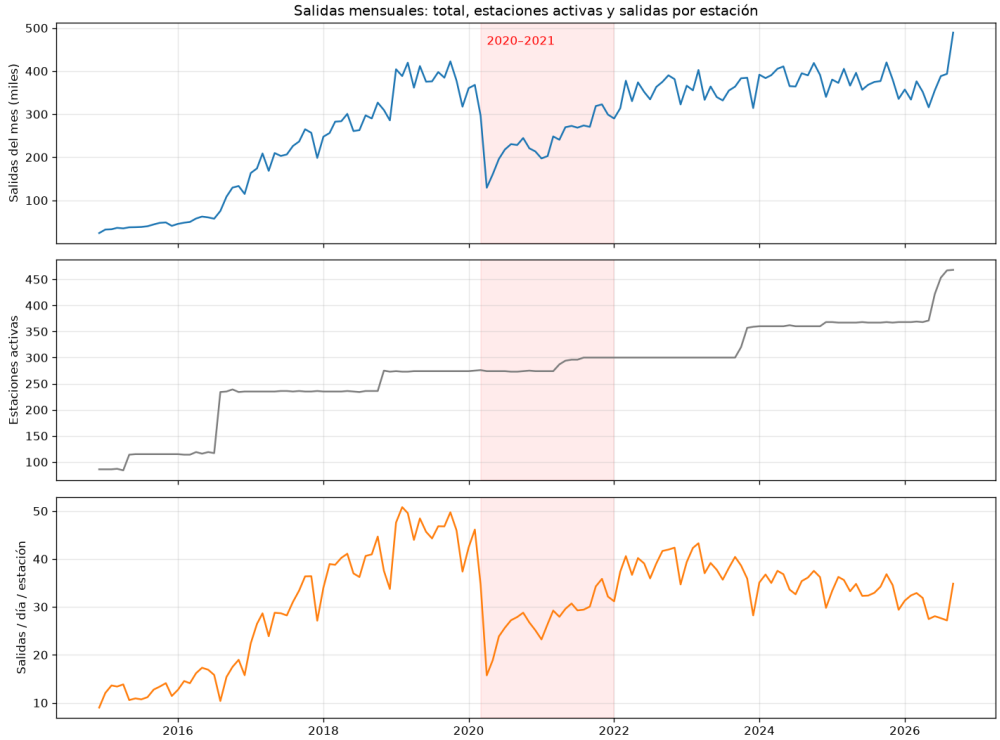


Figura 3. Salidas mensuales, estaciones con actividad y salidas por día y estación. Fuente: notebook 1.02, Erik. El crecimiento del total debe interpretarse junto con los cambios de tamaño y composición de la red.

La detección diaria compara cada fecha con la mediana de hasta ocho semanas previas del mismo día de la semana, con mínimo de cuatro observaciones. Los cocientes inferiores a 0.5 o superiores a 1.5 identifican 136 días atípicos: 105 bajos y 31 altos. Las reglas de calendario y la hipótesis del periodo inicial de la pandemia clasifican 97 casos bajos como comportamiento real; esta clasificación no implica comprobación causal individual.

La integración conserva los días reales y marca los eventos extraordinarios. También reconoce que un detector de totales puede confundir una expansión de estaciones con una anomalía y que la diferencia entre primer y último viaje no demuestra cobertura completa durante el día.

4.3 Expansión de estaciones — José Emmanuel Vázquez Galán

El notebook 1.03 compara estaciones nuevas y consolidadas durante enero–septiembre de 2026. Normaliza por exposición estimada, analiza cohortes y estudia meses desde la primera actividad observada. Las nuevas no tienen la misma cantidad de historia ni exposición que las consolidadas.

Con exposición mensual, las nuevas registran 9.18 salidas por estación-día frente a 32.53 de las consolidadas. El contraste de 1.04 con bordes por día ajusta la intensidad de las nuevas a 10.89 y su porcentaje de ceros de 78.57 % a 74.57 %. Las consolidadas conservan valores redondeados de 32.53 salidas y 53.58 % de ceros. Las cifras todavía incluyen las 24 horas del día, antes de la restricción de servicio de processed.

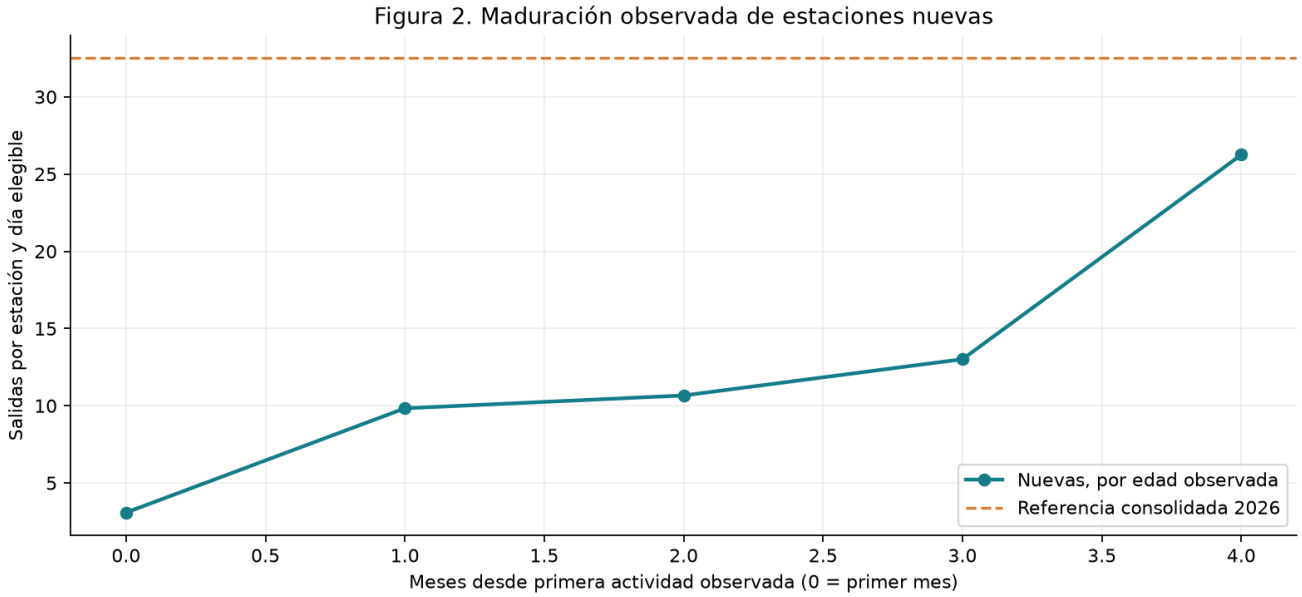


Figura 4. Intensidad observada según edad de las estaciones nuevas, con exposición mensual. Fuente: notebook 1.03, José Emmanuel. El número de estaciones disminuye con la edad observada: el punto de edad cuatro meses reúne solo 12 estaciones y no establece un tiempo universal de maduración.

La comparación mensual incluye días anteriores a la primera actividad dentro del mes inicial y puede sobrestimar ceros. Aun con el ajuste por día, las nuevas presentan menor intensidad. Esto respalda conservarlas y evaluar su desempeño por separado, sin atribuir toda la diferencia a la antigüedad: localización, calendario y disponibilidad también pueden influir.

4.4 Integración del target — Leonardo Santos García

La integración del notebook 1.04 estuvo a cargo de Leonardo Santos García. Las decisiones corresponden al Equipo 04: José Eduardo De Moraes López, Erik Román Cortez, José Emmanuel Vázquez Galán y Leonardo Santos García, con base en la evidencia de los cuatro notebooks. Leonardo integró y documentó esas decisiones y las conectó con su implementación.

El notebook 1.04 valida `station_hour_base`, revisa estaciones representativas, examina distribución del target, rezagos, viajes cortos y horario, y relaciona hallazgos del equipo con las decisiones de procesamiento. Reutiliza figuras, la lista de días atípicos y tablas guardadas en los notebooks, con referencias a sus celdas.

La base de análisis contiene 54.41 % de ceros y una varianza aproximadamente 4.6 veces la media. Estos resultados describen heterogeneidad y dispersión; no bastan para decidir una distribución condicional o un algoritmo. La revisión de picos locales evita eliminar registros únicamente por su magnitud.

La comparación exploratoria de predictores sobre `station_hour_base`, en 2025–2026, obtiene WAPE de 0.625 para el promedio de las últimas cuatro semanas, 0.730 para el rezago semanal, 1.000 para siempre cero y 1.182 para el promedio constante anterior a 2025. Las coberturas de rezagos difieren. El promedio de cuatro semanas para la misma estación, día de la semana y hora se selecciona como referencia predictiva para evaluar posteriormente los modelos de la Fase 2, en concordancia con el ML Canvas. Su valor 0.625 es exploratorio: no corresponde a un modelo final ni a una evaluación recalculada sobre `processed_v1`.

5. Decisiones de preprocesamiento

Las decisiones fueron tomadas por el Equipo 04 con la evidencia de los notebooks 1.01, 1.02, 1.03 y 1.04. Su integración y documentación se encuentran en la sección 8 del notebook 1.04; Leonardo realizó su implementación en `mibici/processed.py`. Las constantes verificables enlazan la justificación colectiva con el código ejecutable.

Decisión	Evidencia y justificación	Resultado aplicado
Estación × hora	Patrones dentro del día y necesidad de localizar las salidas	Una observación por estación e intervalo horario
Inicio en enero de 2022	1.02 muestra un periodo posterior al régimen 2020–2021; 2022 y 2023 son semejantes en medidas agregadas	Ventana 2022-01 a 2026-09; comparación con inicio en 2023 pendiente del modelado
Ceros según actividad observada	Estaciones con altas, bajas y meses sin viajes; sensibilidad de exposición en 1.03	Sin filas anteriores al primer día, posteriores al último ni en meses sin actividad
Solo horario de servicio	Horario publicado de 05:00 a 00:59 y baja actividad observada de madrugada	Se excluyen las horas 1, 2, 3 y 4
Cortos a la misma estación	Retorno en menos de 60 segundos sin cambio neto de inventario al completarse	No se cuentan en el target; permanecen en interim
Cortos entre estaciones	Comparación con la mediana de la misma pareja, sentido y año	Exclusión selectiva con mínimo 30 referencias positivas y duración inferior al 10 % de la mediana
Estaciones nuevas	Menor intensidad e historial corto en 1.03 y su contraste	Se conservan; se agregan antigüedad y cohorte
Días atípicos	Desviaciones no equivalen a registros inválidos	Se conservan festivos, eventos y picos; los eventos documentados llevan marca
Capacidad de nomenclatura	Solo existe la fotografía de septiembre de 2026	No se usa como variable histórica

La referencia para viajes cortos cruzados incluye los viajes positivos de su grupo, sin quitar previamente los menores de 60 segundos. Se conservan los casos sin suficientes referencias y los registrados con resolución al minuto. En la ventana desde 2022, la regla identifica 36,581 viajes de los 49,624 marcados como cortos cruzados. La mediana global de duración de los candidatos es aproximadamente dos segundos. La regla detecta duraciones extraordinariamente cortas; no constituye una comprobación de imposibilidad física basada en distancias.

Las ventanas activas se reconstruyen desde todos los viajes antes de excluir registros del conteo. Así se evita confundir el tratamiento de anomalías con la existencia de una estación. La actividad observada sigue siendo una aproximación: no confirma la apertura efectiva de cada hora ni detecta todos los cierres breves.

En la Fase 1, las medianas por pareja-año y las ventanas de actividad funcionan como reglas retrospectivas de preparación. Para la evaluación temporal y la inferencia de Fase 2, los estadísticos de referencia deberán calcularse únicamente con información

disponible antes del corte correspondiente; la elegibilidad de las estaciones deberá definirse sin consultar actividad futura. Será necesario adaptar o validar esas reglas y reconstruir los conjuntos afectados por cada corte. La documentación del procedimiento no elimina por sí sola el riesgo de fuga temporal de la preparación actual.

El corte de las 22:00 es el contrato acordado para el pronóstico futuro. Que alrededor de 3.6 % de las salidas ocurra después de ese corte no demuestra cuánto cambiará el error predictivo; ese efecto deberá evaluarse posteriormente.

El preprocesamiento aplicado incluye agregación, filtros temporales y de horario, exclusiones del conteo y extracción de calendario y antigüedad. Las variables personales no pasan a processed porque no describen la unidad estación-hora y no conocemos quién viajará al día siguiente. No se aplican escalamiento ni codificaciones específicas de un modelo. La reducción de dimensionalidad no tiene una necesidad demostrada en este conjunto pequeño e interpretable; existe redundancia conocida, como `is_weekend` derivado del día de semana. Las transformaciones aprendidas deberán ajustarse únicamente con entrenamiento cuando corresponda.

6. Dataset procesado

6.1 Flujo y unidad de observación

La arquitectura mantiene la dirección raw → interim → processed. `station_hour_base` es una salida auxiliar de interim utilizada para EDA y validación. El constructor de processed lee directamente los viajes intermedios y reutiliza las funciones de actividad y agregación; no necesita leer el archivo de esa base auxiliar.

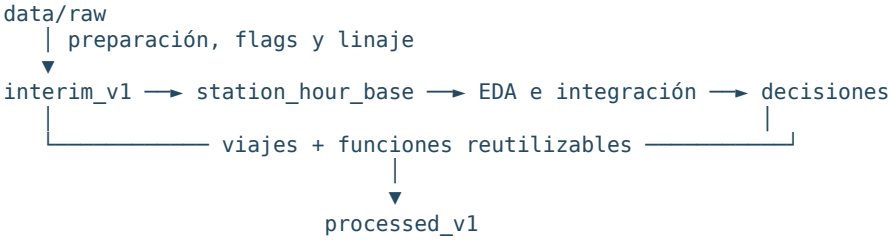


Figura 5. Flujo de datos y decisiones. Elaboración del equipo a partir del pipeline implementado. La base estación × hora apoya el análisis, mientras que el constructor de processed utiliza directamente los viajes de interim y las decisiones documentadas.

El archivo `data/processed/station_hour_v1.parquet` representa una estación durante una hora de servicio de un día elegible. Un valor cero indica ausencia de salidas incluidas en el target dentro de ese intervalo; no demuestra ausencia de necesidad de bicicletas ni disponibilidad efectiva de inventario.

6.2 Dimensiones y columnas

Indicador	processed_v1
Periodo	2022-01-01 a 2026-09-30
Observaciones estación-hora	11,949,160
Estaciones distintas representadas en toda la ventana	473
Salidas incluidas	20,296,886
Intervalos por estación-día elegible	20
Horas con cero salidas	42.8 %
Media de salidas por hora	1.6986
Mediana / p90 / p99	1 / 5 / 12
Máximo	205
Claves duplicadas	0

Las 473 estaciones corresponden a toda la ventana histórica y no al tamaño simultáneo de la red en un día particular. La reducción desde las 486 estaciones de la base completa responde al periodo representado, no a una exclusión general de estaciones nuevas.

Columna	Significado y función
`station_id`	Identificador de estación; categoría, no magnitud
`hour_start`	Inicio de la hora local; junto con estación forma la clave
`departures`	Conteo entero no negativo: target
`hour`	Hora del día, restringida al horario incluido
`day_of_week`	Día de semana, 0 lunes a 6 domingo
`is_weekend`	Indicador de sábado o domingo
`month`	Mes, 1 a 12
`station_age_days`	Días desde la primera actividad observada en todo interim
`is_new_station_cohort`	Marca de primera actividad desde enero de 2026
`is_extraordinary_event`	Marca de fecha con evento extraordinario documentado

Las marcas de cohorte y evento se destinan a segmentar el análisis y la evaluación. No se asume que un evento extraordinario sea información conocida antes del corte. La antigüedad no representa una fecha oficial de inauguración.

6.3 Conciliación y contrato de calidad

Concepto	Viajes
Viajes de interim desde enero de 2022	21,035,317
Menos cortos con regreso a la misma estación	−701,681
Menos cortos cruzados seleccionados por la regla de mediana	−36,581
Menos viajes restantes fuera del horario de servicio	−169
Salidas en `processed_v1`	**20,296,886**

La resta es exacta y coincide con la suma de `departures`. Los 169 viajes de horario cerrado se calculan después de las otras exclusiones para no contar dos veces el mismo registro.

El notebook verifica columnas, ausencia de faltantes y claves duplicadas, inicio de ventana, target no negativo, exclusión de horas cerradas y 20 filas por estación-día elegible. La caída de ceros desde 54.41 % en la base técnica a 42.8 % en processed combina periodo, horario y reglas del target; no se atribuye a un único filtro.

7. Versionado y trazabilidad con MLflow

La trazabilidad combina el control de código en Git, el manifest de las fuentes y el registro de versiones lógicas de datos en MLflow. El servidor local utiliza SQLite en `mlflow/backend/mlflow.db` y un almacén de artefactos en `mlflow/artifacts/`. Su estado, los datasets y las credenciales se mantienen fuera de Git.

Cada construcción registrada crea una corrida en el experimento `mibici-datasets`. El registro contiene:

Elemento	Evidencia que conserva
Parámetros	Reglas, umbrales, ventana, horario y decisiones aplicadas
Métricas	Filas, conteos de calidad, exclusiones y distribución del target
Tags	Etapa, versión, equipo, commit, rama y cambios en archivos rastreados
Artefactos	Resúmenes, esquema, decisiones y evidencia pequeña
Referencia de dataset	Nombre, ubicación, esquema y digest calculado sobre sus filas

Versión registrada	Commit de construcción	Filas	Cambios rastreados sin commit al iniciar
`interim_v1`	`aaa2397`	39,078,226 viajes	No
`processed_v1`	`acd6f1e`	11,949,160 observaciones	No

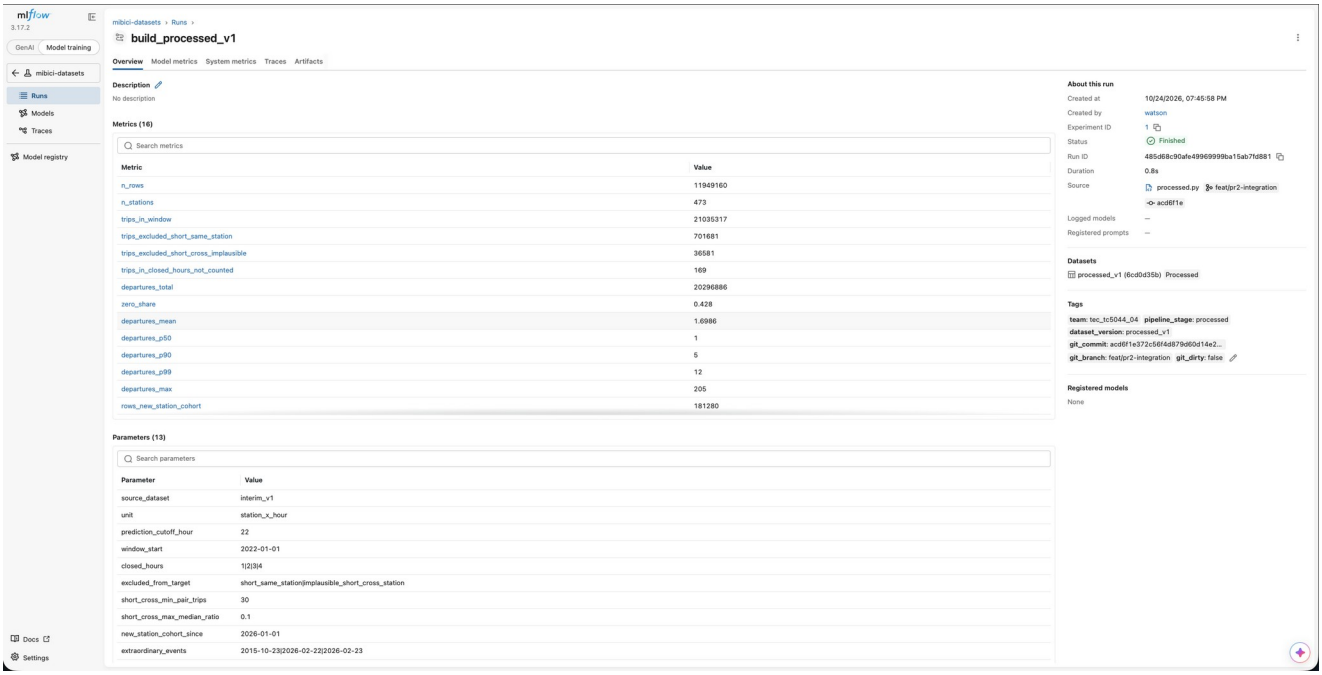


Figura 6. Evidencia del registro de `processed_v1` en MLflow. Fuente: captura conservada por el equipo. La corrida identifica la ejecución que generó los datos; cambios documentales posteriores no alteran ese commit de construcción.

Las capturas del registro de `interim_v1`, correspondientes al primer avance de preparación de datos, se conservan en `reports/evidence/f1_pr1_interim_v1/`. El equipo proporciona además una carpeta de consulta con las imágenes de MLflow de `interim_v1` como evidencia complementaria. Los resultados y la explicación de trazabilidad se incluyen en este reporte para permitir su lectura sin acceder a esa carpeta.

Las capturas del registro de `processed_v1`, correspondientes al segundo avance de integración y preprocesamiento, se conservan en `reports/evidence/f1_pr2_processed_v1/` y en la carpeta de consulta con las imágenes de MLflow de `processed_v1`. Este enlace complementa la evidencia incluida en el documento.

El digest permite contrastar la identidad del contenido, pero no sustituye el dataset. MLflow no recibe los Parquet completos ni conserva por sí mismo una copia recuperable de cada versión. La regeneración requiere las fuentes correspondientes y el código que aplicó las reglas. Los hashes de raw, el linaje por viaje y los reportes facilitan esa auditoría.

Esta solución registra versiones de datasets y no versiones de modelos entrenados. `station_hour_base` conserva su propio resumen técnico; no se presenta como una tercera versión registrada en MLflow.

8. Estructuración, refactorización y reproducibilidad

El repositorio utiliza Cookiecutter Data Science para separar código, datos, notebooks, pruebas y evidencia. Los notebooks se concentran en preguntas, visualización e interpretación; la lógica estable se encuentra en módulos reutilizables.

Componente	Responsabilidad
`dataset.py` y `profiling.py`	Adquisición y diagnóstico de fuentes
`preparation.py`	Normalización, linaje, duración, flags y duplicados
`stations.py`	Catálogo, actividad y ciclo de vida observado
`interim.py`	Lectura, orquestación y escritura de interim
`station_hour.py`	Grilla, conteo por hora y calendario
`processed.py`	Aplicación de decisiones, salida procesada y reportes
`tracking.py`	Registro de datasets y metadatos en MLflow

El diseño prioriza módulos y funciones para las transformaciones deterministas que no requieren mantener estado entre llamadas. Esta organización facilita reutilizar las reglas y probarlas con entradas sintéticas y responsabilidades acotadas. La lectura, escritura y registro se concentran en los orquestadores. Los helpers propios de tracking también se implementan como funciones que utilizan la API de MLflow. En Fase 2 se evaluará la encapsulación en clases cuando un componente necesite gestionar estado o comportamiento compartido, como los estimadores; esa necesidad no se presupone para las transformaciones actuales.

`environment.yml` declara el ambiente Conda `mibici`, con Python 3.12 y conda-forge como estrategia principal. El Makefile proporciona comandos reproducibles para adquisición, perfilado, construcción de capas, servidor local, pruebas y lint. El ambiente se actualiza desde la configuración versionada y el kernel se registra con el nombre del proyecto.

La secuencia de reproducción es preparar el ambiente, adquirir raw, iniciar MLflow y construir interim y processed. `make station-hour` permite regenerar la base auxiliar para ejecutar la integración. Los notebooks del equipo y el CSV de días atípicos completan las dependencias de la evidencia analítica. La ejecución de estas etapas es explícita; no se afirma que exista todavía un único comando que orqueste toda la entrega.

La suite ejecutada en el ambiente `mibici` obtuvo **31 pruebas satisfactorias**. Ruff no detectó errores y confirmó **15 archivos correctamente formateados**. Las pruebas cubren normalización, formatos, flags, ciclo de vida, grilla, conteos, exclusiones y columnas de processed. La revisión estática se aplica al paquete según la configuración de `pyproject.toml`; los notebooks incorporan además verificaciones de esquema, conteos y conciliación.

9. Roles e interacción del equipo

Los roles se entienden como responsabilidades del ciclo MLOps y no como puestos exclusivos. Una persona puede participar en varias funciones.

Rol	Responsables y actividades	Evidencia e interacción
Data Engineer	Leonardo: adquisición, perfilado, preparación, linaje y actividad de estaciones	Entrega interim como insumo común al EDA; incorpora las reglas acordadas de calidad y exposición
Data Scientist	José Eduardo: patrones temporales; Erik: estacionalidad y anomalías; José Emmanuel: expansión; Leonardo: integración del target	Notebooks 1.01–1.04; sus hallazgos alimentan las decisiones del procesamiento
Software Engineer	Leonardo: modularización, pruebas, lint, revisión de dependencias y documentación	Módulos, pruebas y revisión de reproducibilidad; el ajuste del 1.01 surge de esa revisión
ML Engineer	Leonardo: construcción de processed y registro de versiones de datasets	Convierte decisiones analíticas en parámetros, código y corridas auditables
SRE / reproducibilidad	Erik: incorporación de MLflow; José Eduardo: ajuste de dependencias y reproducción del resumen; Leonardo: ambiente y servidor local	Makefile, environment y PR de configuración; facilitan la ejecución común, sin infraestructura productiva desplegada

La interacción principal fue Data Engineer → Data Scientist → decisiones del equipo → integración e implementación por Software/ML Engineer. Los cuatro integrantes aportaron evidencia y participaron en las decisiones; la integración, documentación e implementación técnica estuvieron a cargo de Leonardo. Un ejemplo verificable es la revisión del notebook 1.01: se identificó una entrada sin generación documentada, el autor agregó la construcción y el integrador contrastó los resultados. Otro es el análisis de expansión, cuyo denominador mensual fue refinado por la integración sin atribuir ese contraste al autor del EDA original.

10. Actividad en GitHub y contribuciones individuales

El repositorio público MiBici contiene contribuciones identificables de los cuatro integrantes. Su historial de la rama principal conserva los commits de autor y las integraciones de los PR #1–#7. La evidencia vincula la preparación, el EDA y la integración con contribuciones individuales y una base de código compartida.

Integrante	Contribución verificable	PR o evidencia
Erik Román Cortez	Dependencia MLflow; EDA de estacionalidad y anomalías; lista de días atípicos	PR #1 y PR #4; notebook 1.02
José Emmanuel Vázquez Galán	EDA de expansión, cinco figuras y conclusiones sobre estaciones nuevas	PR #3; notebook 1.03
José Eduardo De Moraes López	EDA temporal y ajuste de reproducibilidad y dependencias	PR #5 y PR #6; notebook 1.01
Leonardo Santos García	Adquisición y perfilado; preparación; revisión e integración; base y dataset procesado; MLflow y pruebas	PR #2 y PR #7; notebook 1.04 y módulos

La colaboración se refleja en ramas temáticas, entregas individuales y correcciones derivadas de revisión. El historial conserva la autoría del trabajo integrado. No se equipara el número de commits con el valor de la contribución.

El PR #7, correspondiente a `feat/pr2-integration`, se integró a `main` el 25 de octubre de 2026 mediante el merge commit `fbb7a3e`. Esta integración incorpora la base estación × hora, el notebook 1.04, las reglas de processed, sus reportes, las pruebas y la documentación. El commit de integración es distinto del commit de construcción registrado en MLflow: cada uno identifica una acción diferente y ambos forman parte de la trazabilidad.

11. Resultados de la Fase 1

11.1 Resultados técnicos

Resultado	Evidencia
Adquisición trazable	143 archivos fuente y manifest con SHA-256
Dataset intermedio	39,078,226 viajes; reportes de esquema, calidad y linaje
Base de análisis	28,246,536 filas, 486 estaciones y conservación de todas las salidas intermedias
Dataset procesado	11,949,160 filas, 473 estaciones y 20,296,886 salidas
Conciliación	Cada viaje desde 2022 queda contabilizado o explicado por una exclusión
Versionado lógico	Corridas de interim y processed con reglas, métricas, Git y digest
Calidad de código	31 pruebas satisfactorias; Ruff sin errores en su alcance configurado
Colaboración	Cuatro notebooks temáticos e integración; contribuciones de los cuatro integrantes

11.2 Hallazgos analíticos

El EDA muestra variación intradiaria, diferencias entre laborales y fines de semana, estacionalidad mensual y cambios de nivel a lo largo del histórico. También evidencia que las nuevas estaciones requieren atención diferenciada y que el criterio de actividad afecta tanto ceros como promedios. Estos hallazgos justifican decisiones del dataset; no constituyen una estimación de mejora operativa.

La comparación de referencias sencillas indica señal semanal útil para iniciar el modelado posterior. Por ello, el promedio de las últimas cuatro semanas para la misma estación, día de la semana y hora constituye la referencia predictiva seleccionada para Fase 2. Se recalculará sobre `processed_v1`, con las reglas temporales revisadas y las mismas observaciones y periodos de evaluación que los modelos supervisados. Sus métricas y las de los modelos se registrarán en MLflow para hacer reproducible la comparación. El WAPE exploratorio de 0.625 no establece un umbral definitivo de desempeño ni una métrica de impacto operativo.

12. Conclusiones y reflexión

La Fase 1 permitió pasar de archivos abiertos heterogéneos a un dataset de salidas por estación y hora con reglas explícitas, conciliación y trazabilidad. Su principal resultado metodológico es la conexión entre problema de negocio, evidencia del EDA, decisiones de preprocesamiento e implementación reproducible.

El equipo identificó que tratar todas las horas sin viajes como ceros equivalentes puede distorsionar el target. También distinguió anomalías estadísticas de errores: los festivos y los picos locales se conservan, mientras que ciertas exclusiones se aplican únicamente al conteo y permanecen auditables en interim. La revisión de los notebooks mejoró reproducibilidad y comparabilidad entre análisis con distintos denominadores.

Las limitaciones que condicionan la interpretación son las siguientes:

- Los viajes realizados no contienen demanda no satisfecha, inventario ni ocupación de anclajes. No se puede cuantificar directamente una reducción de estaciones vacías o llenas.
- Los datos públicos se publican por mes. El contrato diario requiere simulación histórica o una fuente más oportuna para operar.
- La disponibilidad se aproxima desde actividad observada; no existe un calendario completo de aperturas, cierres temporales y operación por estación-hora.
- La nomenclatura es una fotografía. No se atribuye su capacidad a fechas anteriores como si fuera un dato histórico.
- La antigüedad se mide desde la primera observación. Las estaciones recientes tienen seguimiento corto y la curva de maduración cambia de composición conforme aumenta la edad.
- No hay variables de clima ni un calendario de festivos incorporado al dataset procesado. Las hipótesis sobre causas de variaciones no deben presentarse como explicaciones demostradas.
- Las medianas por pareja-año y las ventanas de actividad se obtienen del histórico disponible. Al diseñar una evaluación temporal deberá revisarse qué información puede usarse en cada corte, aunque todavía no haya rezagos en processed.

La preparación queda lista para iniciar experimentación controlada, no para afirmar que existe un modelo listo para producción. La siguiente fase deberá comprobar referencias, particiones temporales y tratamiento de estaciones con poco historial. La selección desde 2022 es una decisión inicial defendible con evidencia agregada, pendiente de contrastarse predictivamente con otras ventanas.

13. Uso de inteligencia artificial

El equipo utilizó herramientas de inteligencia artificial como apoyo a la generación de código, depuración, análisis y documentación. Las decisiones de negocio y preprocesamiento, la interpretación de resultados y la responsabilidad académica corresponden a los integrantes. La siguiente tabla identifica las herramientas, modelos y finalidades declarados para cada contribución.

Integrante	Herramienta y modelo	Finalidad
José Eduardo De Moraes López	Gemini, Google	Apoyo a la carga y agregación por bloques anuales del notebook 1.01, parametrización de gráficas y estructuración de su análisis escrito
Erik Román Cortez	Claude, Anthropic, modelo Opus	Apoyo en la elaboración del código del notebook 1.02
José Emmanuel Vázquez Galán	ChatGPT, OpenAI, modelo GPT-6	Apoyo en código y documentación del notebook 1.03
Leonardo Santos García	Claude Code, Anthropic, modelo Claude Opus 5.5	Generación de código, depuración, verificación de resultados y redacción preliminar de la preparación e integración
Leonardo Santos García	ChatGPT, OpenAI, modelo GPT Sol 5.6	Planeación y revisión de la estrategia del pipeline
Leonardo Santos García	Codex, OpenAI, basado en GPT-6	Apoyo en consulta de fuentes del proyecto, verificación de cifras, revisión técnica y redacción del reporte

El contenido generado para el notebook 1.04 y su código asociado fue revisado, ejecutado y validado por el integrador, Leonardo Santos García. Las decisiones son del Equipo 04 y el equipo asume la responsabilidad final de lo entregado. La IA se utiliza como apoyo al trabajo de los integrantes y no sustituye la validación técnica ni la responsabilidad sobre los resultados.

Referencias de las herramientas: Gemini, Claude Code, ChatGPT y Codex. Las denominaciones de modelos se reproducen conforme a las declaraciones de uso de los integrantes.

Referencias y evidencia del reporte

La siguiente relación identifica las fuentes de requerimientos, resultados y evidencia. Las tablas e interpretaciones incluidas en el reporte permiten su lectura autónoma; el repositorio público conserva el detalle técnico y los archivos de respaldo.

Fuente	Contenido utilizado
`M2_05_Fase 1_ Avance de Proyecto.pdf`	Requisitos, rúbrica, formato y declaración de IA
ML Canvas v3	Requerimientos y propuesta de valor vigentes
Reporte de diagnóstico	Cobertura, fuentes y formulación inicial; sus propuestas se contrastan con las decisiones posteriores
Reporte PR1	Preparación, flags, linaje y registro de interim
Reporte PR2	Integración, decisiones, roles y resultados; el estado final de integración se respalda con el PR #7
`reports/interim/quality_summary.json` y `schema.json`	Conteos y esquema de interim
`reports/station_hour/summary.json`	Dimensiones y distribución de la base de análisis
`reports/processed/summary.json`, `schema.json` y `decisions.json`	Resultado procesado, columnas, reglas y conciliación
Notebooks 1.01, 1.02, 1.03 y 1.04	Métodos, figuras, interpretaciones y resultados guardados
`mibici/`, `tests/`, `Makefile`, `environment.yml` y README	Implementación, ejecución y reproducibilidad
Historial de `main`, PR #7 y `reports/evidence/`	Autoría, integración y evidencia de corridas MLflow