TC5044.10

FASE 1

MiBici

Preparación, exploración y trazabilidad de datos para el pronóstico de salidas por estación y hora.



Fase 1 — Avance de Proyecto

Tecnológico de Monterrey

Operaciones de Aprendizaje Automático

Equipo 04

José Eduardo De Moraes López — A01634782
Erik Román Cortez — A01793714
José Emmanuel Vázquez Galán — A01797507
Leonardo Santos García — A01797367

25 de octubre de 2026

RESUMEN EJECUTIVO

Una base reproducible para llegar al modelado

Problema

Anticipar dónde y cuándo se concentran las salidas observadas para apoyar la priorización del rebalanceo.

Propuesta

Preparar una base estación × hora, trazable y reproducible, para experimentar con modelos en la siguiente fase.

Límite

La Fase 1 habilita experimentación predictiva. No es un modelo en producción ni optimiza rutas.

142	39,078,226	11,949,160	31	Git + MLflow
archivos mensuales	viajes · interim_v1	estación × hora · processed_v1	pruebas satisfactorias	trazabilidad lógica

Mensaje ejecutivo

Se construyó el fundamento de datos, calidad y trazabilidad que permite pasar a backtesting y modelado sin confundir preparación con desempeño predictivo.

El valor está en anticipar salidas, no en resolver toda la operación

Beneficiario propuesto

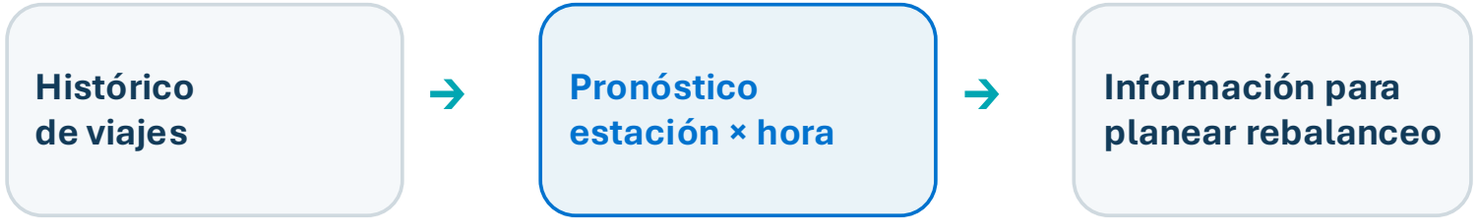
Coordinación de operaciones y logística de MiBici. Supuesto del equipo, sin validación directa.

Necesidad

Priorizar estaciones y franjas horarias con mayor concentración de salidas observadas.

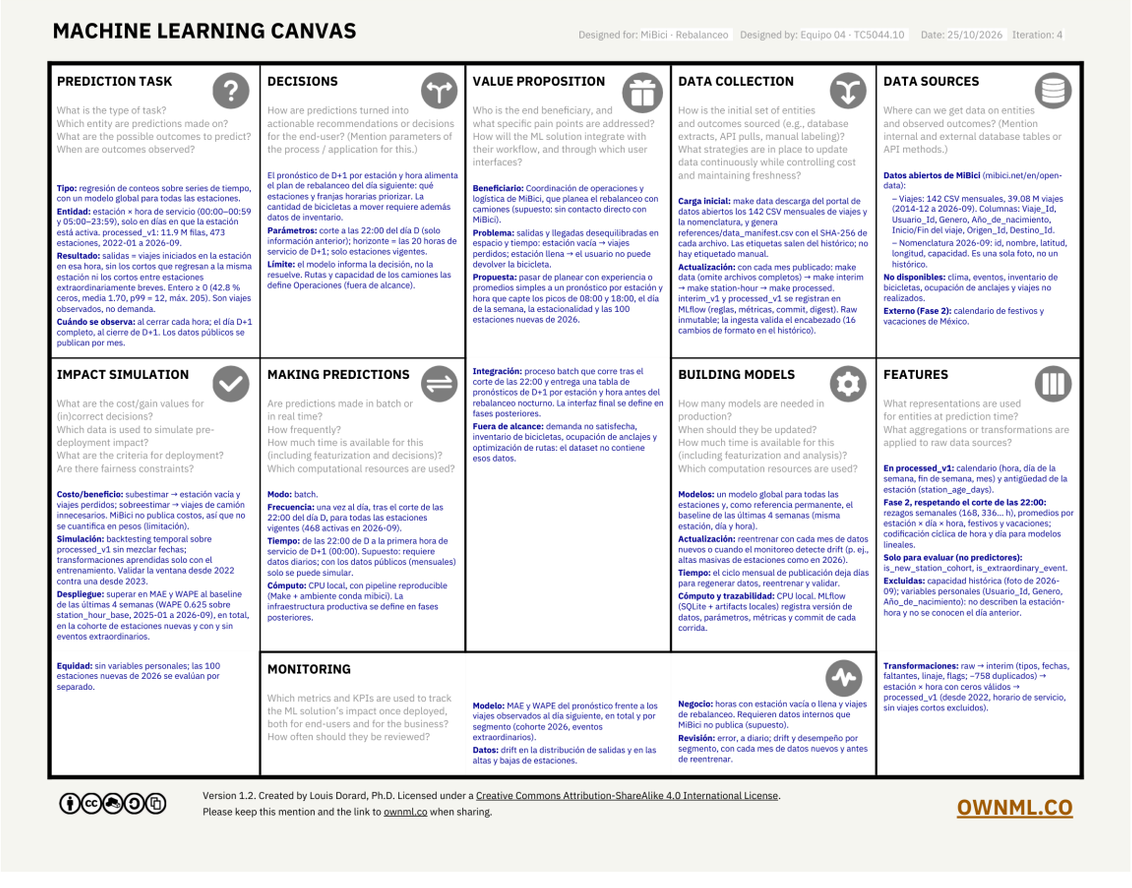
Valor esperado

Aportar información para una planeación más proactiva. Sin beneficio económico cuantificado.



Alcance: conteo de viajes iniciados. No hay inventario, ocupación de anclajes ni demanda no satisfecha.

Un contrato de predicción acota qué se quiere predecir y cuándo



MACHINE LEARNING CANVAS

Designed for: MiBici · Rebalanceo | Designed by: Equipo 04 · TC5044.10 | Date: 25/10/2026 | Iteration: 4

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Tipo: regresión de conteos sobre series de tiempo, con un modelo global para todas las estaciones.
Entidad: estación × hora de servicio (00:00–00:59 y 05:00–23:59), solo en días en que la estación está activa. processed_v1: 11.9 M filas, 473 estaciones, 2022-01 a 2026-09.
Resultado: salidas = viajes iniciados en la estación en esa hora, sin los cortos que regresan a la misma estación ni los cortos entre estaciones extraordinariamente breves. Entero ≥ 0 (42.8 % ceros, media 1.70, p99 = 12, máx. 205). Son viajes observados, no demanda.
Cuándo se observa: al cerrar cada hora; el día D+1 completo, al cierre de D+1. Los datos públicos se publican por mes.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

El pronóstico de D+1 por estación y hora alimenta el plan de rebalanceo del día siguiente: qué estaciones y franjas horarias priorizar. La cantidad de bicicletas a mover requiere además datos de inventario.
Parámetros: corte a las 22:00 del día D (solo información anterior); horizonte = las 20 horas de servicio de D+1; solo estaciones vigentes.
Límite: el modelo informa la decisión, no la resuelve. Rutas y capacidad de los camiones las define Operaciones (fuera de alcance).

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiario: Coordinación de operaciones y logística de MiBici, que planea el rebalanceo con camiones (supuesto; sin contacto directo con MiBici).
Problema: salidas y llegadas desequilibradas en espacio y tiempo: estación vacía → viajes perdidos; estación llena → el usuario no puede devolver la bicicleta.
Propuesta: pasar de planear con experiencia o promedios simples a un pronóstico por estación y hora que capte los picos de 08:00 y 18:00, el día de la semana, la estacionalidad y las 100 estaciones nuevas de 2026.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Carga inicial: make data descarga del portal de datos abiertos los 142 CSV mensuales de viajes y la nomenclatura, y genera references/data_manifest.csv con el SHA-256 de cada archivo. Las etiquetas salen del histórico; no hay etiquetado manual.
Actualización: con cada mes publicado: make data (omite archivos completos) → make interim → make station-hour → make processed. interim_v1 y processed_v1 se registran en MLflow (reglas, métricas, commit, digest). Raw inmutable; la ingesta valida el encabezado (16 cambios de formato en el histórico).

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Datos abiertos de MiBici (mibici.net/en/open-data):
– Viajes: 142 CSV mensuales, 39.08 M viajes (2014-12 a 2026-09). Columnas: Viaje_Id, Usuario_Id, Genero, Año_de_nacimiento, Inicio/Fin del viaje, Origen_Id, Destino_Id.
– Nomenclatura 2026-09: id, nombre, latitud, longitud, capacidad. Es una sola foto, no un histórico.
No disponibles: clima, eventos, inventario de bicicletas, ocupación de anclajes y viajes no realizados.
Externo (Fase 2): calendario de festivos y vacaciones de México.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costo/beneficio: subestimar → estación vacía y viajes perdidos; sobreestimar → viajes de camión innecesarios. MiBici no publica costos, así que no se cuantifica en pesos (limitación).
Simulación: backtesting temporal sobre processed_v1 sin mezclar fechas; transformaciones aprendidas solo con el entrenamiento. Validar la ventana desde 2022 contra una desde 2023.
Despliegue: superar en MAE y WAPE al baseline de las últimas 4 semanas (WAPE 0.625 sobre station_hour_base, 2025-01 a 2026-09), en total, en la cohorte de estaciones nuevas y con y sin eventos extraordinarios.

Equidad: sin variables personales; las 100 estaciones nuevas de 2026 se evalúan por separado.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Modo: batch.
Frecuencia: una vez al día, tras el corte de las 22:00 del día D, para todas las estaciones vigentes (468 activas en 2026-09).
Tiempo: de las 22:00 de D a la primera hora de servicio de D+1 (00:00). Supuesto: requiere datos diarios; con los datos públicos (mensuales) solo se puede simular.
Cómputo: CPU local, con pipeline reproducible (Make + ambiente conda mibici). La infraestructura productiva se define en fases posteriores.

Integración: proceso batch que corre tras el corte de las 22:00 y entrega una tabla de pronósticos de D+1 por estación y hora antes del rebalanceo nocturno. La interfaz final se define en fases posteriores.
Fuera de alcance: demanda no satisfecha, inventario de bicicletas, ocupación de anclajes y optimización de rutas: el dataset no contiene esos datos.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Modelos: un modelo global para todas las estaciones y, como referencia permanente, el baseline de las últimas 4 semanas (misma estación, día y hora).
Actualización: reentrenar con cada mes de datos nuevos o cuando el monitoreo detecte drift (p. ej., altas masivas de estaciones como en 2026).
Tiempo: el ciclo mensual de publicación deja días para regenerar datos, reentrenar y validar.
Cómputo y trazabilidad: CPU local. MLflow (SQLite + artifacts locales) registra versión de datos, parámetros, métricas y commit de cada corrida.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

En processed_v1: calendario (hora, día de la semana, fin de semana, mes) y antigüedad de la estación (station_age_days).
Fase 2, respetando el corte de las 22:00: rezagos semanales (168, 336… h), promedios por estación × día × hora, festivos y vacaciones; codificación cíclica de hora y día para modelos lineales.
Solo para evaluar (no predictores): is_new_station_cohort, is_extraordinary_event.
Excluidas: capacidad histórica (foto de 2026-09); variables personales (Usuario_Id, Genero, Año_de_nacimiento): no describen la estación-hora y no se conocen el día anterior.

Transformaciones: raw → interim (tipos, fechas, faltantes, linaje, flags; −758 duplicados) → estación × hora con ceros válidos → processed_v1 (desde 2022, horario de servicio, sin viajes cortos excluidos).

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

Modelo: MAE y WAPE del pronóstico frente a los viajes observados al día siguiente, en total y por segmento (cohorte 2026, eventos extraordinarios).
Datos: drift en la distribución de salidas y en las altas y bajas de estaciones.
Negocio: horas con estación vacía o llena y viajes de rebalanceo. Requieren datos internos que MiBici no publica (supuesto).
Revisión: error, a diario; drift y desempeño por segmento, con cada mes de datos nuevos y antes de reentrenar.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.
OWNML.CO

Unidad

estación × hora

Target

salidas observadas

Corte

antes de 22:00, día D

Horizonte

día D+1

Servicio

00:00–00:59 y 05:00–23:59

Modalidad futura

batch

Los archivos públicos son mensuales: el contrato diario aún solo puede estudiarse mediante simulación histórica.

Plantilla: Machine Learning Canvas v1.2, Louis Dorard, Ph.D. · CC BY-SA 4.0 · ownml.co

DATOS DE ORIGEN Y PREPARACIÓN

143 archivos fuente preservados y trazados por SHA-256

142	1	39,078,984	dic. 2014 → sep. 2026
CSV mensuales de viajes	nomenclatura · sep. 2026	registros originales	cobertura histórica

Adquisición → **Validación de formatos** → **Normalización** → **Control de calidad** → **interim_v1**

Raw inmutable

Los archivos originales se almacenan sin modificación manual.

Manifest

Nombre, URL, tamaño y SHA-256 identifican las fuentes utilizadas.

LIMPIEZA Y CALIDAD

La capa intermedia elimina solo 758 duplicados exactos

39,078,984
registros originales

− 758
duplicados exactos

=

39,078,226
viajes en interim_v1

Encabezados, tipos y fechas

Normalización explícita

Faltantes

Unificación a nulos reales

Duración

Fin − inicio, en segundos

Anomalías

Flags de calidad, sin borrado automático

Linaje

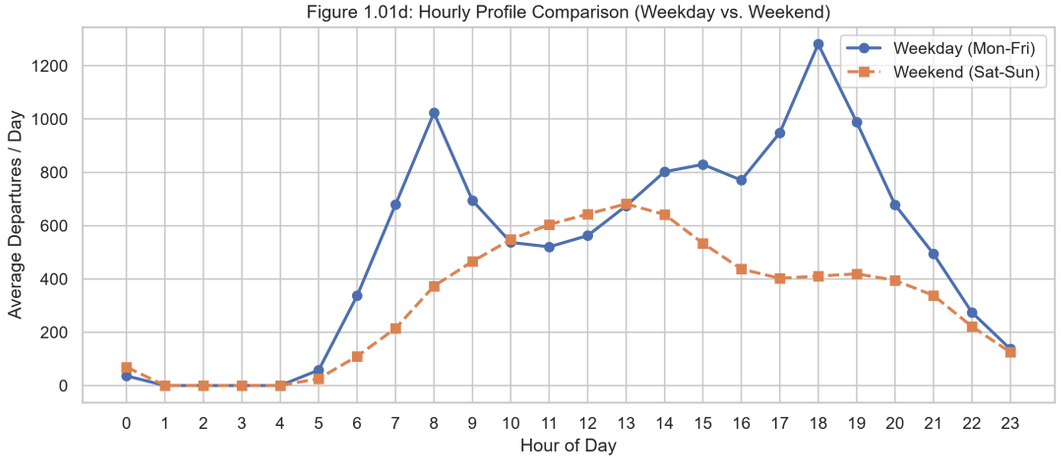
source_file + source_sha256

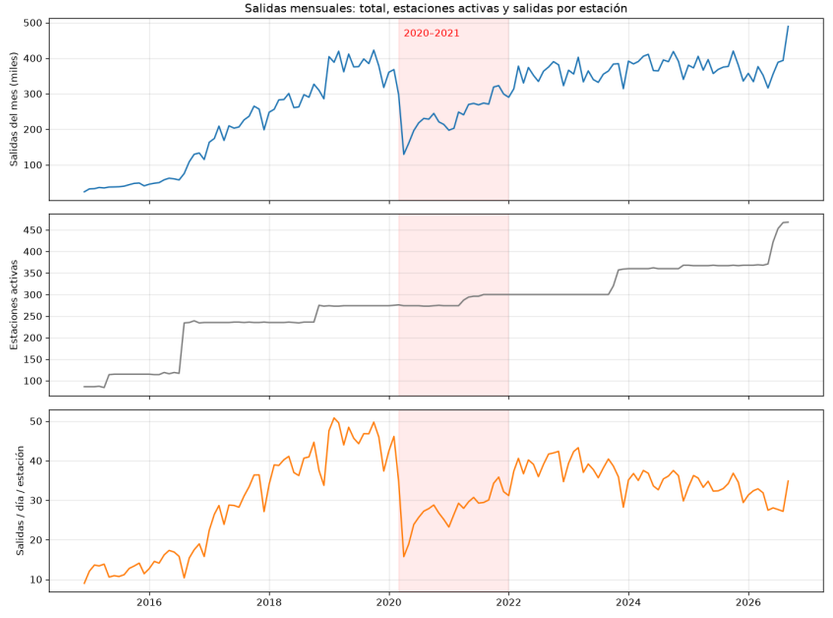
Estaciones

Catálogo + actividad observada

Importante: los flags pueden coincidir en un mismo viaje. No deben sumarse como categorías excluyentes.

La demanda observada cambia por hora, calendario y periodo





Perfil horario: laborales vs. fin de semana

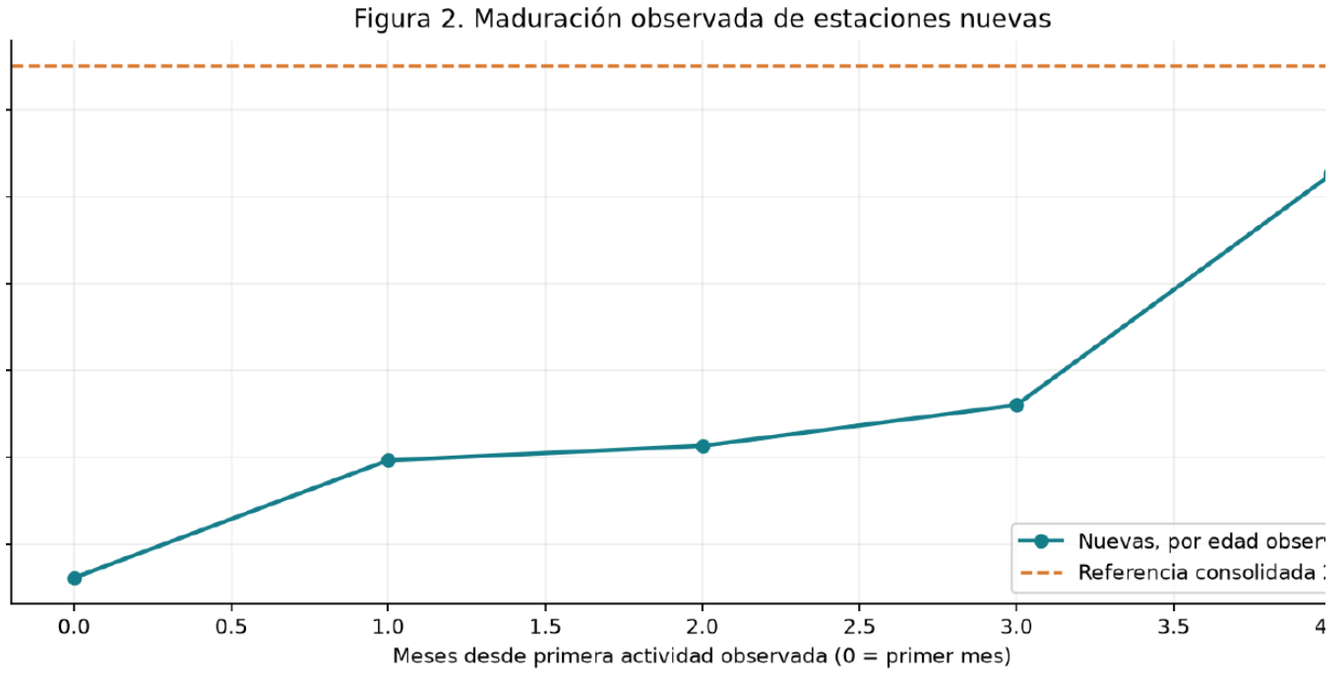
Dos picos laborales alrededor de 08:00 y 18:00; el fin de semana concentra más actividad hacia el mediodía.

Evolución mensual y tamaño de red

Variación estacional y cambio marcado en 2020–2021. La evidencia apoya una ventana inicial desde 2022, pendiente de validación predictiva.

Interpretación: asociaciones descriptivas. El dataset no registra motivos de viaje.

Las estaciones nuevas requieren evaluación diferenciada



(figura 2 del notebook 1.03)

100

estaciones con primera actividad desde ene. 2026

Hallazgo

Las estaciones nuevas muestran menor intensidad observada y menos historial/exposición.

Implicación para ML

Conservarlas y evaluar su desempeño por separado.

Primera actividad observada ≠ fecha oficial de inauguración. La curva es descriptiva y no una trayectoria universal.

DECISIONES

El EDA se traduce en reglas explícitas de preprocesamiento

Hallazgo / decisión	Aplicación	Justificación
Estación × hora	Unidad del target	Localizar patrones dentro del día
Desde ene. 2022	Ventana inicial	Separar el régimen 2020–2021
Ceros por actividad	No crear exposición ficticia	Altas, bajas y meses sin viajes
20 horas de servicio	Excluir 01:00–04:59	Horario publicado por MiBici
Viajes cortos	Exclusión selectiva del target	Reglas auditables; permanecen en interim
Estaciones nuevas	Conservar + antigüedad/cohorte	Historial corto y menor intensidad
Días atípicos	Conservar + marca de evento	Atípico no equivale a inválido
Capacidad	Excluir como histórico	Solo foto de sep. 2026

Escalamiento, codificación específica y reducción de dimensionalidad se reservan para el modelado, cuando exista necesidad y puedan ajustarse sin fuga.

DATASET PROCESADO Y CONCILIACIÓN

processed_v1 separa con claridad viajes de observaciones estación × hora

raw → interim_v1 → **processed_v1**

station_hour_base auxiliar para EDA, no etapa obligatoria de lectura

11,949,160

observaciones estación × hora

473

estaciones en toda la ventana

42.8 %

horas con cero salidas

Conciliación exacta

21,035,317 viajes desde enero de 2022
− 701,681 cortos, misma estación
− 36,581 cortos cruzados seleccionados
− 169 fuera del horario de servicio
= 20,296,886 salidas procesadas

Periodo: enero de 2022 a septiembre de 2026 · 0 claves estación-hora duplicadas

VERSIONADO Y TRAZABILIDAD

Git, hashes y MLflow conectan código, fuentes y datasets

Git

Versiones de código y cambios

Manifest + SHA-256

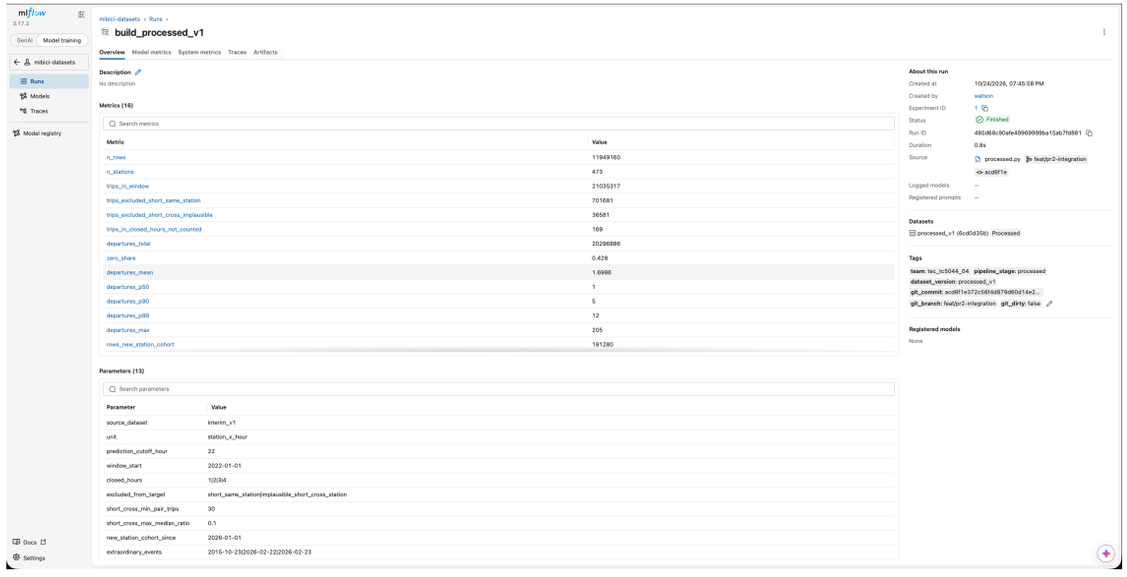
Identidad de fuentes

MLflow

Corridas, parámetros, métricas, tags, artefactos y referencias

Parquet

Almacenamiento físico de datos preparados



39,078,226

interim_v1 · viajes

11,949,160

processed_v1 · observaciones

MLflow registra versiones lógicas y referencias. No almacena una copia completa recuperable de los Parquet.

En Fase 1 se versionan datasets, no modelos entrenados.

ARQUITECTURA Y REFACTORIZACIÓN

Código modular y pruebas convierten decisiones en un pipeline reproducible

data/
fuentes y capas

mibici/
módulos reutilizables

notebooks/
EDA e integración

tests/
pruebas

reports/
resultados y evidencia

environment.yml
dependencias

Makefile
comandos

Separación de responsabilidades

Adquisición y diagnóstico → preparación y calidad → actividad de estaciones → agregación estación-hora → dataset procesado → tracking de datasets.

31
pruebas

Python 3.12
ambiente Conda

Ruff sin errores en el alcance configurado · 15 archivos correctamente formateados

No se afirma despliegue productivo, CI completa ni un único comando para reproducir toda la entrega.

COLABORACIÓN Y GITHUB

Cuatro contribuciones convergen en decisiones colectivas e integración técnica

José Eduardo

EDA temporal · notebook 1.01 · reproducibilidad

Erik

Estacionalidad/anomalías · notebook 1.02 · apoyo MLflow

José Emmanuel

Expansión/maduración · notebook 1.03

Leonardo

Adquisición, preparación, integración, processed, refactorización, MLflow y pruebas

Preparación común → EDA por integrante → decisiones colectivas → integración técnica → validación y Pull Requests

Roles funcionales: Data Engineer · Data Scientist · Software Engineer · ML Engineer · SRE/reproducibilidad

Evidencia de colaboración

github.com/LeonardoSantosGrc/MiBici · historial de main e integraciones de PR #1–#7

La Fase 1 cierra preparación; la Fase 2 debe demostrar capacidad predictiva

Resultados alcanzados

- Datos interim y processed con reglas documentadas
- Cuatro notebooks de EDA e integración
- Trazabilidad de datasets y código
- Conciliación y validación de calidad
- Base lista para experimentación

Limitaciones

- Publicación mensual
- Sin inventario ni demanda no satisfecha
- Actividad observada ≈ disponibilidad
- Riesgo de fuga temporal en reglas retrospectivas
- Sin modelo final ni beneficio medido

Fase 2

- Modelos supervisados
- Backtesting temporal
- Recalcular baseline en processed_v1
- Comparar MAE y WAPE
- Evaluar estaciones nuevas
- Registrar experimentos en MLflow

El WAPE 0.625 es una referencia exploratoria sobre station_hour_base. No es desempeño de un modelo final.

La declaración detallada de uso de IA se presenta en la diapositiva siguiente.

TRANSPARENCIA ACADÉMICA

Uso de IA declarado por el equipo y apoyo a esta presentación

José Eduardo De Moraes López — Google. (2026). Gemini (Gemini 1.5 Pro / Flash) [Modelo de lenguaje grande], utilizado para generación de código del notebook 1.01 (carga y agregación por bloques anuales, parametrización de gráficas) y estructuración de su análisis escrito. https://gemini.google.com/.

Erik Román Cortez — Anthropic. (2026). Claude (modelo Opus) [Modelo de lenguaje grande], utilizado para generación de código del notebook 1.02. https://claude.ai/.

José Emmanuel Vázquez Galán — OpenAI. (2026). ChatGPT (GPT-6) [Modelo de lenguaje grande], utilizado para generación de código y documentación del notebook 1.03. https://chatgpt.com/.

Leonardo Santos García — Anthropic. (2026). Claude Code (Claude Opus 5.5) [Modelo de lenguaje grande], utilizado para generación de código, depuración, verificación de resultados y redacción preliminar de la preparación e integración. https://claude.com/claude-code.

Leonardo Santos García — OpenAI. (2026). ChatGPT (GPT Sol 5.6) [Modelo de lenguaje grande], utilizado para planeación y revisión de la estrategia del pipeline. https://chatgpt.com/.

Leonardo Santos García — OpenAI. (2026). Codex (basado en GPT-6) [Modelo de lenguaje grande], utilizado para consulta de fuentes del proyecto, verificación de cifras, revisión técnica y redacción del reporte. https://openai.com/codex/.

Equipo 04 — presentación ejecutiva — Microsoft. (2026). Microsoft 365 Copilot [Asistente de IA], utilizado para la síntesis, estructura y diseño de la presentación ejecutiva. https://www.microsoft.com/microsoft-365/copilot.

Las decisiones, la interpretación y la responsabilidad académica permanecen en el Equipo 04.