MACHINE LEARNING CANVAS

Designed for: MiBici · Rebalanceo | Designed by: Equipo 04 · TC5044.10 | Date: 24/10/2026 | Iteration: 2

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Tipo: regresión de conteos sobre series de tiempo, con un modelo global para todas las estaciones.

Entidad: estación × hora, solo en los días en que la estación está activa (28.2 M filas, 486 estaciones, 2014-12 a 2026-09).

Resultado: salidas = viajes iniciados en la estación en esa hora; entero ≥ 0 (54.4 % ceros, media 1.38, p99 = 11, máx. 207). Son viajes observados, no demanda: los no realizados por falta de bicicleta no se registran.

Cuándo se observa: al cerrar cada hora; el día D+1 completo se conoce al cierre de D+1. Los datos públicos se publican por mes.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

El pronóstico de D+1 por estación y hora alimenta el plan de rebalanceo del día siguiente: qué estaciones priorizar, en qué franja horaria y cuántas bicicletas mover aproximadamente.

Parámetros: pronóstico al cierre del día D; horizonte de 24 h; granularidad horaria; solo estaciones vigentes.

Límite: el modelo informa la decisión, no la resuelve. Rutas y capacidad de los camiones las define Operaciones (fuera de alcance).

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiario: Coordinación de operaciones y logística de MiBici, que planea el rebalanceo con camiones (supuesto: sin contacto directo con MiBici).

Problema: salidas y llegadas desequilibradas en espacio y tiempo: estación vacía → viajes perdidos; estación llena → el usuario no puede devolver la bicicleta.

Propuesta: pasar de planear con experiencia o promedios simples a un pronóstico por estación y hora que capte hora, día de la semana, estacionalidad, tendencia de la red y las 100 estaciones nuevas de 2026.

Integración: proceso batch nocturno que entrega una tabla de pronósticos de D+1 por estación y hora como insumo del plan del día. La interfaz final se define en fases posteriores.

Fuera de alcance: demanda no satisfecha, inventario de bicicletas, ocupación de anclajes y optimización de rutas: el dataset no contiene esos datos.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Carga inicial: make data descarga del portal de datos abiertos los 142 CSV mensuales de viajes y la nomenclatura, y genera references/data_manifest.csv con el SHA-256 de cada archivo.

Las etiquetas salen del propio histórico de viajes; no hay etiquetado manual.

Actualización: con cada mes publicado: make data (omite archivos completos) → make interim → make station-hour; cada versión se registra en MLflow (reglas, calidad, commit, digest). Raw inmutable; la ingesta valida el encabezado (16 cambios de formato en el histórico).

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Datos abiertos de MiBici (mibici.net/en/open-data):

- Viajes: 142 CSV mensuales, 39.08 M viajes (2014-12 a 2026-09). Columnas: Viaje_Id, Usuario_Id, Genero, Año_de_nacimiento, Inicio/Fin del viaje, Origen_Id, Destino_Id.
- Nomenclatura 2026-09: id, nombre, latitud, longitud, capacidad. Es una sola foto, no un histórico.

No disponibles: clima, eventos, inventario de bicicletas, ocupación de anclajes y viajes no realizados.

Externo opcional: calendario de días festivos (fase posterior).

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costo/beneficio: subestimar → estación vacía y viajes perdidos; sobreestimar → viajes de camión innecesarios. MiBici no publica costos, así que no se cuantifica en pesos (limitación).

Simulación: backtesting temporal con ventanas que avanzan sobre los meses más recientes; periodo de prueba pendiente por la expansión de 2026.

Despliegue: superar en MAE y WAPE a los baselines D-7 (misma hora, semana anterior) y promedio de 4 semanas, en total y por segmento (pico/valle, nueva/consolidada).

Equidad: sin variables personales (usuario, género, edad); estaciones nuevas evaluadas por separado.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Modo: batch.

Frecuencia: una vez al día, al cierre del día D, para todas las estaciones vigentes (468 activas en 2026-09).

Tiempo: entre el cierre de D y el inicio de la operación de D+1. Supuesto: requiere datos diarios; con los datos públicos (mensuales) solo se puede simular.

Cómputo: CPU local, con pipeline reproducible (Make + ambiente conda mibici). La infraestructura productiva se define en fases posteriores.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Modelos: un modelo global para todas las estaciones, con los dos baselines como referencia permanente.

Actualización: reentrenar con cada mes de datos nuevos o cuando el monitoreo detecte drift (p. ej., altas masivas de estaciones como en 2026).

Tiempo: el ciclo mensual de publicación deja días para regenerar datos, reentrenar y validar.

Cómputo y trazabilidad: CPU local. MLflow (backend SQLite + artifacts locales) registra versión de datos, parámetros, métricas y commit de cada corrida.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Disponibles el día anterior (sin fuga temporal): calendario (hora, día de la semana, fin de semana, mes); rezagos de 1 y 7 días a la misma hora; medias de 7 y 28 días; llegadas; antigüedad de la estación; tamaño de la red; coordenadas y municipio.

Excluidas: capacidad como dato histórico (es una foto de 2026-09); is_new_station e is_retired_by_activity (usan información futura); variables personales.

Transformaciones: raw → interim (tipos, 2 formatos de fecha, faltantes, linaje, flags; −758 duplicados exactos) → estación × hora con ceros válidos solo en periodos activos.

Pendiente (EDA): viajes < 60 s y ventana de entrenamiento.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

Modelo: MAE y WAPE del pronóstico frente a los viajes observados al día siguiente, en total y por segmento (pico/valle, nueva/consolidada).

Datos: drift en la distribución de salidas y en las altas y bajas de estaciones.

Negocio: horas con estación vacía o llena y viajes de rebalanceo. Requieren datos internos que MiBici no publica (supuesto).

Revisión: error, a diario; drift y desempeño por segmento, con cada mes de datos nuevos y antes de reentrenar.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO