MACHINE LEARNING CANVAS

Designed for: MiBici · Rebalanceo | Designed by: Equipo 04 · TC5044.10 | Date: 25/10/2026 | Iteration: 4

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Tipo: regresión de conteos sobre series de tiempo, con un modelo global para todas las estaciones.

Entidad: estación × hora de servicio (00:00–00:59 y 05:00–23:59), solo en días en que la estación está activa. processed_v1: 11.9 M filas, 473 estaciones, 2022-01 a 2026-09.

Resultado: salidas = viajes iniciados en la estación en esa hora, sin los cortos que regresan a la misma estación ni los cortos entre estaciones extraordinariamente breves. Entero ≥ 0 (42.8 % ceros, media 1.70, p99 = 12, máx. 205). Son viajes observados, no demanda.

Cuándo se observa: al cerrar cada hora; el día D+1 completo, al cierre de D+1. Los datos públicos se publican por mes.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

El pronóstico de D+1 por estación y hora alimenta el plan de rebalanceo del día siguiente: qué estaciones y franjas horarias priorizar. La cantidad de bicicletas a mover requiere además datos de inventario.

Parámetros: corte a las 22:00 del día D (solo información anterior); horizonte = las 20 horas de servicio de D+1; solo estaciones vigentes.

Límite: el modelo informa la decisión, no la resuelve. Rutas y capacidad de los camiones las define Operaciones (fuera de alcance).

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiario: Coordinación de operaciones y logística de MiBici, que planea el rebalanceo con camiones (supuesto: sin contacto directo con MiBici).

Problema: salidas y llegadas desequilibradas en espacio y tiempo: estación vacía → viajes perdidos; estación llena → el usuario no puede devolver la bicicleta.

Propuesta: pasar de planear con experiencia o promedios simples a un pronóstico por estación y hora que capte los picos de 08:00 y 18:00, el día de la semana, la estacionalidad y las 100 estaciones nuevas de 2026.

Integración: proceso batch que corre tras el corte de las 22:00 y entrega una tabla de pronósticos de D+1 por estación y hora antes del rebalanceo nocturno. La interfaz final se define en fases posteriores.

Fuera de alcance: demanda no satisfecha, inventario de bicicletas, ocupación de anclajes y optimización de rutas: el dataset no contiene esos datos.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Carga inicial: make data descarga del portal de datos abiertos los 142 CSV mensuales de viajes y la nomenclatura, y genera references/data_manifest.csv con el SHA-256 de cada archivo. Las etiquetas salen del histórico; no hay etiquetado manual.

Actualización: con cada mes publicado: make data (omite archivos completos) → make interim → make station-hour → make processed. interim_v1 y processed_v1 se registran en MLflow (reglas, métricas, commit, digest). Raw inmutable; la ingesta valida el encabezado (16 cambios de formato en el histórico).

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Datos abiertos de MiBici (mibici.net/en/open-data):

- – Viajes: 142 CSV mensuales, 39.08 M viajes (2014-12 a 2026-09). Columnas: Viaje_Id, Usuario_Id, Genero, Año_de_nacimiento, Inicio/Fin del viaje, Origen_Id, Destino_Id.
- – Nomenclatura 2026-09: id, nombre, latitud, longitud, capacidad. Es una sola foto, no un histórico.

No disponibles: clima, eventos, inventario de bicicletas, ocupación de anclajes y viajes no realizados.

Externo (Fase 2): calendario de festivos y vacaciones de México.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costo/beneficio: subestimar → estación vacía y viajes perdidos; sobreestimar → viajes de camión innecesarios. MiBici no publica costos, así que no se cuantifica en pesos (limitación).

Simulación: backtesting temporal sobre processed_v1 sin mezclar fechas; transformaciones aprendidas solo con el entrenamiento. Validar la ventana desde 2022 contra una desde 2023.

Despliegue: superar en MAE y WAPE al baseline de las últimas 4 semanas (WAPE 0.625 sobre station_hour_base, 2025-01 a 2026-09), en total, en la cohorte de estaciones nuevas y con y sin eventos extraordinarios.

Equidad: sin variables personales; las 100 estaciones nuevas de 2026 se evalúan por separado.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Modo: batch.

Frecuencia: una vez al día, tras el corte de las 22:00 del día D, para todas las estaciones vigentes (468 activas en 2026-09).

Tiempo: de las 22:00 de D a la primera hora de servicio de D+1 (00:00). Supuesto: requiere datos diarios; con los datos públicos (mensuales) solo se puede simular.

Cómputo: CPU local, con pipeline reproducible (Make + ambiente conda mibici). La infraestructura productiva se define en fases posteriores.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Modelos: un modelo global para todas las estaciones y, como referencia permanente, el baseline de las últimas 4 semanas (misma estación, día y hora).

Actualización: reentrenar con cada mes de datos nuevos o cuando el monitoreo detecte drift (p. ej., altas masivas de estaciones como en 2026).

Tiempo: el ciclo mensual de publicación deja días para regenerar datos, reentrenar y validar.

Cómputo y trazabilidad: CPU local. MLflow (SQLite + artifacts locales) registra versión de datos, parámetros, métricas y commit de cada corrida.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

En processed_v1: calendario (hora, día de la semana, fin de semana, mes) y antigüedad de la estación (station_age_days).

Fase 2, respetando el corte de las 22:00: rezagos semanales (168, 336… h), promedios por estación × día × hora, festivos y vacaciones; codificación cíclica de hora y día para modelos lineales.

Solo para evaluar (no predictores): is_new_station_cohort, is_extraordinary_event.

Excluidas: capacidad histórica (foto de 2026-09); variables personales (Usuario_Id, Genero, Año_de_nacimiento): no describen la estación-hora y no se conocen el día anterior.

Transformaciones: raw → interim (tipos, fechas, faltantes, linaje, flags; −758 duplicados) → estación × hora con ceros válidos → processed_v1 (desde 2022, horario de servicio, sin viajes cortos excluidos).

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

Modelo: MAE y WAPE del pronóstico frente a los viajes observados al día siguiente, en total y por segmento (cohorte 2026, eventos extraordinarios).

Datos: drift en la distribución de salidas y en las altas y bajas de estaciones.

Negocio: horas con estación vacía o llena y viajes de rebalanceo. Requieren datos internos que MiBici no publica (supuesto).

Revisión: error, a diario; drift y desempeño por segmento, con cada mes de datos nuevos y antes de reentrenar.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO